

交接：ColliderAgent 论文表格 S3/S4/S5 的实验状态（2026-09-24；首版 2026-09-17）

分支 feat/skill-evolution-v2 (ColliderAgent 仓库)。9/24 更新：S5 的 Opus 4.6 ×3 已完成（轻量 7 题 21 次 20 次成功），Model B 用 Codex + gpt-5.5 跑了 2 题；全部数据、逐次指标和结果图在 docs/paper/results-2026-09-24/（见该目录 README），bench_runs/ 的沙盒已删除。第 6 节是更新摘要，第 1-5 节保留 9/17 的原文。LaTeX 版逐条对照在 docs/paper/claims-audit-2026-09-24.tex（已编译成 PDF）。

1. 已有结果：Opus 4.6 (xhigh) 一轮全 benchmark

Benchmark	时长 [h]	子 agent	Magnus jobs	文件	输入 tokens [M]	输出 [k]	USD	模型延迟占比	结果
Scalar LQ m_ej (2005.06475 Fig. 2)	6.41	2	42	28	214.0	220	-	0.65	TBD (见脚注 a)
ALP EFT E_T^miss (1701.05379 Fig. 8)	0.86	3	6	17	36.9	56	22	0.78	成功
U(1)' scan (1605.02910 Fig. 1)	1.05	3	17	25	5.1	16	9	0.69	成功 *
U1 LQ mono-tau (1811.07920 Fig. 3)	4.00	2	29	19	181.4	219	106	0.68	TBD (见脚注 b)
Heavy N (1308.2209 Fig. 3)	0.40	3	7	18	3.2	13	4	0.72	成功
General Z' (2103.02708 Fig. 4)	0.66	3	7	16	19.4	38	13	0.80	成功
KK graviton (9909255 Fig. 2)	1.35	2	16	14	4.2	51	6	0.33	成功 *
U1 LQ at MuC eta (2104.05720 Fig. 11)	0.55	0	14	2	1.3	5	6	0.47	成功
U1 LQ at MuC reach (2104.05720 Fig. 12)	1.41	3	25	23	27.3	52	21	0.64	成功 *

* = 端到端完成、形状一致、数值偏差记 footnote (footnote 原文在各沙盒 verdict.yaml，汇总在 aggregate 输出末尾)。

其他模型 (ALP EFT 一题各一次，全部成功)：Opus 5 0.87 h / \$9.06；Opus 4.8 1.05 h / \$12.55；Sonnet 5 1.38 h / \$7.54。Opus 5 另跑了 U(1)' scan 一次 (成功，\$14.32)，3 TeV 面板与 Opus 4.6 给出完全相同的轮廓。更正 (9/24)：Codex/gpt-5.5 用同一 prompt 复现出了论文的尖端 ($\tilde{g} \approx -0.72$, $g_1' \approx 0.65$)，所以该 25% 偏差是 Claude run 的分析选择，不是 prompt 的限制；原先“来自 prompt 的分析流程而非 agent”的说法撤回。

2. 两个 TBD 及其根因 (需要你补跑)

a. Scalar LQ m_ej (2005.06475 Fig. 2) — 跑了 6.4 h 被我停掉，无图。

- 已完成：模型、验证、10 万事件 LUXlep parton 样本、LHE 轻子 → 光子替换、Pythia8 Check:event 旁路。
- 卡点：10 万事件的 Delphes ROOT 文件 27 GB，launch job 的打包空间只有 10 GB，两次 Pythia8+Delphes launch 都在上传阶段报 “No space left on device”。第三次 launch 用 MG5 的 ! shell 命令在 run 结束后删掉 HepMC/ROOT 只留 LHCO (写法见 src/skills/madgraph-simulator/SKILL.md 的 “Output size” 一节，commit 61800a9)，停掉时正在跑。
- 补跑建议：直接用当前 skills 重跑一次 (scripts/bench/run_benchmark.sh 2005.06475 2 claude-opus-4-6 --effort high)，预计 1.5-2 h。或在原沙盒续跑：bench_runs/20260916T220031Z_2005.06475_fig2_claude-opus-4-6/，用 scripts/bench/README.md 里的续跑 prompt。
- 参考图：paper-reproduction/2005.06475/paper/tex_source/backgrounds.pdf。

b. U1 LQ mono- τ (1811.07920 Fig. 3) — 第一次尝试记为失败 (infrastructure)。

- 已完成：模型、18 个 Delphes run (ATLAS/CMS $\times$ 9 质量点)。中间 4 个 9-run 的 launch 因同一个 10 GB 限制在上传阶段失败，agent 改成每批 3 个 run 后成功。
- 卡点：事件生成完成后 orchestrator 以“等待下载”结束回合，无头会话随即终止，没有跑分析。已在 orchestrator skill 里禁止 (commit e7c5b61)。
- 续跑结果 (同一沙盒新开会话，1.7 h、\$29.5)：图形状与论文一致，但排除限在所有质量点比论文弱 20-35%，RH R_D(*) 带因此未被排除。续跑图在 bench_runs/20260916T220116Z_1811.07920_fig3_claude-opus-4-6/output/figures/u1_exclusion.png，verdict 在同目录 verdict_continuation.yaml。
- 补跑建议：用当前 skills 完整重跑一次 (scripts/bench/run_benchmark.sh 1811.07920 3 claude-opus-4-6 --effort high)，预计 1.5-2 h；若排除限仍偏弱，记 footnote (两次独立实现都偏弱则是 prompt 流程问题)。
- 参考图：paper-reproduction/1811.07920/1811.07920/U1_exc.jpeg。

3. Table S4 / S5 计划

- **S5 (Opus 4.6 $\times$ 3)**：每个 benchmark 再跑 2 次。用 --effort high (xhigh 下两个 Delphes 题分别花了 \$106 和约 \$200，其余 \$4-22)。同时最多并行 4 个。每次跑完：scripts/bench/judge.sh <sandbox> <参考图>，人工确认 verdict.yaml，再 aggregate.py。判定标准：端到端完成且大致一致即成功，数值偏差进 footnote；失败模式按论文的 model / generation / analysis / infrastructure 四类。
- **S4 列 B = GPT-5.3-Codex + Codex CLI** (与 Opus 4.6 同日发布 2026-02-05，Codex 原生模型)：用 codex-com 分支的 skills-only 模式，同样的 prompt，每次一个干净目录；时长/jobs/tokens 从 Codex 会话日志取。
- **S4 列 C = Sonnet 5** (或 Opus 5)：scripts/bench/run_benchmark.sh <arxiv> <fig> claude-sonnet-5，先各一次。
- 参考图位置 (判图用)：ALP 1701.05379/paper/tex_source/Figs/AP_pho_METdist.png；U(1) 1605.02910/paper/tex_source/figures/{2000,2500,3000}.pdf；Heavy N 1308.2209/ref/1308.2209/inc14.pdf；General Z 2103.02708/paper/2103.02708/Figure_004-{a,b,c}.pdf；KK graviton 9909255/paper/9909255/nlc_shape.ps (fig 2)；MuC 2104.05720/paper/tex_source/figures/DY_histo_{high,low}_beta.pdf (fig 11)；DYreach.pdf (fig 12)。

4. 运行注意事项 (都已写进 skills 或 harness，但补跑时请知晓)

1. 无头模式必须 CLAUDE_CODE_PRINT_BG_WAIT_CEILING_MS=0 (harness 已设)，否则子 agent 超过 10 分钟会被杀。
2. claude -p 的 usage 只算主会话，tokens 要用 metrics.json 里的 tokens_in_total (含子 agent)。
3. Delphes launch：每个 job $\leq$ 3 个 10k run，或用！清理；不要把 9 个 run 放一个 launch。
4. Opus 4.6 有 1/9 的概率不触发 orchestrator (MuC Fig. 11 那次自己在主会话跑完，子 agent 调用 0 次，结果正确)。

5. 在同一台机器的后台 Bash 里直接起 `claude -p` 可能报 "Not logged in" ; 用 `run_benchmark.sh (setsid nohup)` 启动就没问题。
6. 每个沙盒的 `.claude-config/agent-memory/` 里有子 agent 写的 lesson , 跑完用 `python3 scripts/memory/distill.py import --from <sandbox>/.claude-config/agent-memory` 并入中央库 ; 目前中央库 28 条 , 其中 2 条已在 2 次独立 run 里重复出现 (并行 launch 的 `run_name` 冲突 ; 默认值等于请求值时无法察觉 set 行被吞) 。

5. 费用与时间参考

Opus 4.6 xhigh 一轮 9 个 prompt 共约 \$190 (Scalar LQ 未计 , 估计 >\$100); 轻量题 0.4-1.4 h、\$4-22 , Delphes 题 4-6 h、\$100 以上。三个 S4/S5 的完整矩阵 (8 benchmark × 3 模型 × 3 次) 按 high 估算 \$1000-1500、集群 2-3 天。

6. 2026-09-24 更新

- **S5 (Opus 4.6 xhigh ×3)**: 7 个轻量 benchmark 第 2、3 次全部跑完 , 21 次里 20 次成功 ; 唯一失败是 MuC Fig. 11 第 2 次 (model : LQ 曲线与 SM 逐 bin 只差 2-3%)。Scalar LQ 与 mono- τ 没有补跑 (每次 4-6 h、>\$100) , 仍是脚注 a / b 的状态。本轮 14 次有效 run 共 \$102.56。
- **Table S3** : 改为 3 次成功尝试的均值 , 逐次数值在 results-2026-09-24/runs.csv ; 模型延迟占比 21 次的范围 0.23-0.80、中位数 0.55。
- **S4 列 B** : GPT-5.3-Codex 在 ChatGPT 登录的 Codex 里不可用 (需 API key) , 改用 gpt-5.5 : ALP EFT 1/1 (0.99 h)、U(1)' 1/1 (1.03 h , 3 TeV 面板与论文一致) ; mono- τ 1/1 (2.55 h , 成功但排除限弱约 30 % , 与 Opus 续跑的偏弱一致 , 见 README 第 3 节) ; Scalar LQ 1/1 (4.41 h , 成功但峰值归一化低约 2 倍 , 说明该题用当前 skills 可以端到端完成)。列 C 留白。
- **harness** 修正 : 沙盒里复制的 .credentials.json 会在主账号刷新 token 后失效 (4 个 run 死于 "OAuth session expired") , run_benchmark.sh 改为符号链接共享凭据 ; judge.sh 的 JSON 解析能修复分号/尾逗号 ; aggregate.py 新增 --extra (合并沙盒已删的文档数据) 和 --csv。
- **U(1)' 3 TeV** 面板的说法更正 : 见第 1 节。
- 交接时仍缺 : Scalar LQ / mono- τ 的 Opus 4.6 ×3 ; GPT-5.3-Codex (API key) ; 列 B 其余 5 题及 ×3 ; 列 C。命令见 results-2026-09-24/README.md 第 5 节。

7. 2026-09-26 更新 : Model C 与综合 S4

全部数据与中文说明在 docs/paper/results-2026-09-26/ (README、tables.md、runs.csv、longhorizon_*.md、figures/) , LaTeX 对照在 claims-audit-2026-09-24.tex 的 "Model C and the comprehensive Table S4" 一节。

- **C 列** = 仓库自带的 **python-agent (Google ADK 单循环) + Gemini 3.1 Pro preview** (经 api.openlux.ai 中转 , OpenAI 兼容格式) : 轻量 7 题 ×3 得 **8/21** , 13 次失败里 10 次是 150 次调用上限耗尽 (多数卡在事例生成的报错循环 , 上下文最高 379k tokens) ; 两个重题都失败。

- 对照：同一个 Gemini 3.1 Pro 放进 Gemini CLI 0.61 (skills-only) 7/7、平均 0.63 h；gpt-5.5 放进同一个 ADK 循环 7/7 (平均 35 次调用、4 次报错)，但两个重题都退回 parton 级近似 (Scalar LQ 跳过 Delphes, mono- τ 用 LHE 级动力学做选择；均判失败)。结论：结构差异是主因，前沿模型在轻量题上能掩盖它，重题上掩盖不了。
- **B 列改用 GPT-5.3-Codex** (API key 登录，与 Opus 4.6 同日发布)：轻量 5/7 (两个 MuC 题失败：耦合未生效、空等高线)，mono- τ 成功且最接近论文，Scalar LQ 失败 (LUXlep PDF 安装问题后放弃)。gpt-5.5 的 4 题结果保留为 B'。
- **Opus 5 补齐 7 题**：7/7 (MuC reach 4.3 h，主 agent 自行判断统计噪声后派子 agent 补样)。
- 基准有效性：Magnus 作业列表共享，一次 Codex run 读了 9/16 的作业日志直接出图 (已隔离重跑)。现在所有 harness 的 prompt 附带 scripts/bench/benchmark_rules.md，每个沙盒用 scripts/bench/job_provenance.py 核对作业来源；本轮其余 52 个 run 全部通过。
- 补跑方法 (沙盒放 /playpen1, BENCH_RUNS_DIR=/playpen1/shiqiu/collideragent-bench_runs)：
- ADK：scripts/bench/run_benchmark_adk.sh <arxiv> <fig> gemini-3.1-pro-preview|gpt-5.5 --no-wait, key 在 ~/.config/collideragent/openlux.env / openai.env (仓库外，勿提交)；venv 用 cd python-agent && uv sync --extra analysis。
- Gemini CLI：scripts/bench/run_benchmark_gemini.sh <arxiv> <fig> gemini-3.1-pro-preview --no-wait, 需 ~/.gemini/settings.json 设 security.auth.selectedType=gemini-api-key、security.folderTrust.enabled=false。
- Codex 5.3-codex：codex login --with-api-key 后 scripts/bench/run_benchmark_codex.sh <arxiv> <fig> gpt-5.3-codex --no-wait。
- 汇总：scripts/bench/pack_results.py <runs_dir> <out_dir> --extra docs/paper/results-2026-09-24/documented_runs.json；长程指标：scripts/bench/longhorizon_table.py <runs_dir>。
- 仍缺：Opus 4.6 的 Scalar LQ / mono- τ $\times 3$ ；Opus 5 与 GPT-5.3-Codex 的 $\times 3$ ；若要更严格地分离“结构 vs 模型”，把 Anthropic 模型放进 ADK 循环 (需要 Anthropic API key 经 LiteLLM)。